

FAI产品大模型方案对比与部署

0. 文档记录

1. 背景与核心场景

2. 公有云模型厂商对比：微软 (Azure OpenAI) vs. DeepSeek

2.1 核心指标详细对比表

2.2 公有云建议结论

3. 部署模式对比：在线公有云 vs. 私有化部署

3.1 公有云 (SaaS)

3.2 私有化部署

3.3 客户利益与风险对照表

4. 私有部署模型规模影响

4.1 核心指标详细对比表——模型大小

4.2 核心指标详细对比表——模型选型(qwen\llama)

4.3 私有部署建议结论

4.4 不同Agent推荐模型大小表

5. 部署方案与成本参考 (供售前报价参考)

5.1 FAI 大模型部署方案全景对比表

5.2 技术架构图

6. 常见问题应答 (FAQ)

0. 文档记录

文档版本	内容	作者	日期	相关人
1.0	创建文档	张千晓、郭吉善	2026/1/5	市场部、售前顾问、项目交付团队

1. 背景与核心场景

背景：为了确保前方团队在面对客户关于“模型选择”、“数据安全”及“私有化部署”的咨询时能准确应答，本报告对FAI所采用的大模型方案进行了全面梳理。

核心业务场景：智能模拟分析与报告生成。

文档结构：背景描述->厂商对比->部署模式对比（公有vs私有）->规模对比（大vs小、厂商llama vs 厂商qwen）->落地方案与成本。

2. 公有云模型厂商对比：微软 (Azure OpenAI) vs. DeepSeek

测试背景：针对“单次模拟分析”场景，分别使用**GPT-5.1**和**DeepSeek-V3.2**跑**10次**测试，截取两个典型案例，如下。

 **gpt-正常.pdf**
302.96KB

 **ds-正常.pdf**
356.32KB

2.1 核心指标详细对比表

	微软 Azure OpenAI (GPT-5.1)	DeepSeek (V3.2)	差异化总结
输出报告成功率	★★★★☆	★★★★★	DS几乎从不失败；gpt偶尔会有失败或者拒绝生成的情况。通过十次测试，DS成功输出9次，GPT成功输出8次（失败文档内容不是模拟分析）
数据准确度	★★★★☆	★★★★★	数据量在8张以下图表的情况下双方效果都很好数据准确。在10+以上gpt会生成简单报告或者 拒绝渲染图片 只输出结论。

			
--	--	--	--

</

格式都ok，gpt偶尔会有存在输出提示词要求以外的内容（包括输出括号内的内容，输出图表颜色设置、输出非文档要求语言的内容）

产线效率与产出分析 - 单次模拟总结报告

1. 摘要总览 (Executive Summary)

1. 产线整体平均节拍 187 秒/件，对应理论产能偏低，与部分工位出现的瓶颈节拍不匹配，显示结构性瓶颈与瓶颈断点。

2. 实际小时产出波动大 (1010 → 1380 Pcs) ，说明 负荷不均衡、局部阻塞与放行策略不稳定。

3. 工位利用率中「等待」时间普遍高达 7400-7500s，显示产线存在 系统性空转与节拍不同步问题。

2. 模拟背景与核心目标

• 模拟场景：本产线包含关键工位：SMT-C、分板区、测试区、浸胶区；数据呈现每小时产出、空转占有、工位节拍与工位利用分布。

• 核心目标：

i. 识别节拍瓶颈与产出限制。

ii. 衡量空间资源配置合理性。

iii. 评估工位利用率与等待浪费。

• 用户关注点：整体产线效率 + 产出表现。

3. 关键结果与深入分析

3.1 生产总览：Panel / Pcs 数量 (文本)

Panel = 700

Pcs = 700

1. 数据观察

700 Panel 与 700 Pcs 完全一致，说明无良率损失，但总产量在日维度偏低，呈现出节拍驱动型产能受限特征。

2. 对比逻辑

虽然产量一致显示过程质量稳定，但与平均节拍 187 秒/件相对照，可确认产线未进入高速节奏，良率虽稳但生产速度较慢。

4. オペレーション推定

原因はステーション間のビート不一致、作業者介入頻度差、設備起動時間のバラツキが濃厚。

3.3 時間帯別産出量

※ scatter → xychart へ変換

色数：1 → #4682B4

gpt响应更快，大概10-20s（数据量越小越快）左右输出报告；

ds则比较慢，1-3min（数据量越小越快）才响应。

SLA差异。 微软有企业级SLA保障（99.9%可用性）；DeepSeek公有API偶尔会因为热度过高而响应慢，但后续可以采取调用Azure、阿里百炼，硅基流动等平台的ds api 优化稳定性。

DeepSeek便宜，便宜20+倍（百万token输出，DS: ¥3，GPT: \$10）如图

DS：

价格	百万tokens输入（缓存命中）	0.2元
	百万tokens输入（缓存未命中）	2元
	百万tokens输出	3元

GPT：

Input: \$1.25
Cached Input: \$0.13
Output: \$10

			经过测试，单次生成分析报告的成本如下： - 从0-1输出一份模拟报告耗费token：0.4w-0.7w。 - 通过3-5次对话优化并生成模拟报告总共耗费token约为：2w-3w （相同条件下，DS模型生成报告所消耗的token量较GPT模型高出约20%左右）
合规安全	★★★★★	★★★★★	微软和DeepSeek都符合合规要求，国内客户建议DeepSeek、国外建议GPT。



关于GPT，

我们使用的是azure的gpt-chat（gpt官方推出的变种模型），并不是原始的gpt，因为没有注册开通不了gpt，理论上使用gpt旗舰模型更合理

由于gpt-5-chat的上下文比gpt-5要小很多，所以输出的报告质量一般应该和模型有关，换成gpt-5应该会好很多

- 需要注册才能访问 gpt-5-pro、gpt-5 和 gpt-5-codex 模型。
- gpt-5-mini、gpt-5-nano 和 gpt-5-chat 不需要注册。

(1) gpt-5-chat 版 2025-10-03 引入了以情感智能和心理健康能力为重点的显著增强。此升级集成了专用数据集和优化响应策略，以提高模型的能力：

- 更准确地理解和解释情感上下文，从而实现更细腻和富有同理心的互动。
- 在与心理健康相关的对话中提供支持、负责任的响应，确保敏感度和遵守最佳做法。

这些改进旨在使 GPT-5 聊天在情感语气和福祉考虑至关重要的情境中更具情境感知、以人为中心且更可靠。

2.2 公有云建议结论

- 对于绝大多数追求成本效益与产出稳定性的业务场景，DeepSeek (V3.2) 是首选方案。它在核心输出能力上表现卓越，且拥有绝对的成本优势。
- 如果客户是国外客户，业务需要满足严格的全球合规框架，同时对响应速度和稳定性又较高要求，应推荐 Azure OpenAI (GPT-5.1)。

3. 部署模式对比：在线公有云 vs. 私有化部署

3.1 公有云 (SaaS)

- **适用客户：**对初期投入敏感、追求最新技术、无绝对物理隔离要求的客户。
- **优势：**
 - **性能最强：**始终使用全球最强的模型。
 - **免维护：**无需客户购买服务器，无需IT运维模型。
 - **弹性扩展：**多人并发使用生成报告时，云端自动扩容，不卡顿。
- **劣势：**数据需传出企业内网（虽然我们会签署隐私协议，且大模型厂商承诺不训练数据）。

3.2 私有化部署

- **适用客户：**军工、涉密单位、大型国企，有严格的数据不出域要求。
- **核心风险提示：**
 - a. **会逐步落后：**客户现在花高价买的显卡服务器，部署了当前的模型。3年后，云端模型已经迭代了3-4代（智商翻倍），但客户私有服务器上的模型还是3年前的“旧脑子”，且硬件可能无法运行未来的新模型。
 - b. **维护黑洞：**私有化环境常常缺乏Python依赖库、网络受限，导致FAI功能升级困难。
 - c. **高昂成本：**不仅仅是硬件成本，还有电力和专人维护成本。

3.3 客户利益与风险对照表

关注点	公有云 (SaaS)	私有化部署
数据安全	数据加密传输，厂商承诺不留存。	数据不出机房，物理隔绝，最高安全级。
初期投入	低（按年订阅或按量付费）。	极高（硬件采购+部署实施费）。
长期性能	持续升级，永远保持最新。	逐渐落后，升级需要重新采购模型包和服务。
适用客户	一般企业、设计院、高校、外企。	军工、涉密单位、大型国央企核心部门。
FAI功能体验	秒级响应，支持超长上下文（处理几十页的仿真日志）。	响应受显卡限制，上下文受显存限制（可能无法一次性分析太长的数据）。

4. 私有部署模型规模影响

4.1 核心指标详细对比表——模型大小

测试背景：针对“单次模拟分析”场景，分别使用qwen8B/32B/235B跑10次测试，截取三个典型案例，如下。

 **qwen8b报告.pdf**
224.47KB

 **qwen32b报告.pdf**
298.25KB

 **qwen235b报告.pdf**
282.88KB

评价维度	最小实验模型(8B)	推荐门槛模型(32B)	推荐旗舰模型(235B)	差异化描述
输出报告成功率	★★★★☆ ☆	★★★★★	★★★★★	旗舰/门槛级均能稳定完成任务；最小模型在生成长篇报告时的内容较差。
数据准确度	★★☆☆☆ ☆	★★★★★☆☆	★★★★★	8B模型风险高，容易产生“幻觉”数据；32B模型表现良好，仅在极少数边缘数据上不如旗舰模型敏锐。
归因逻辑	★★☆☆☆ ☆	★★★★★☆☆	★★★★★	旗舰级能做深度因果推断；门槛级能完成标准归因；最小模型往往只能浅显的输出推导原因和建议，更多的是陈述现象。
上下文长度	★★☆☆☆ ☆	★★★★★☆☆	★★★★★	最小模型经常无法完全理解全部上下文，读取了模拟结果的前半部分，忽略了后半部分的报错信息。 235B和32B上下文是128K 8B长度是32k 上述是总上下文，最大输出理论上（总上下文-所有输入）<总上下文
指令遵循	★★★★☆ ☆	★★★★★	★★★★★	门槛级在遵循“生成JSON”、“不许废话”等指令上表现已经非常成熟，足以支撑业务。

报告格式	★★★★☆ ☆	★★★★★☆☆	★★★★★☆☆	旗舰模型和门槛模型均可生成正确格式的报告，其中门槛模型偶尔会有报告格式不正确的情况（图表仅展示数据未渲染成功），最小模型只能生成文字版报告无法渲染图表
响应速度	★★★★★ ★	★★★★★☆☆	★★★★☆☆☆	最小模型出字最快；门槛级速度适中，体验流畅；旗舰级推理较重，速度相对较慢。
稳定性对比	★★★★☆ ☆	★★★★★☆☆	★★★★★☆☆	门槛级已具备企业级稳定性；最小模型上下文太小指令理解和输出内容的稳定性差。
硬件成本	💰	💰💰	💰💰💰💰	旗舰级需昂贵的服务器集群；门槛级仅需双卡工作站；最小模型单张消费级显卡即可。

4.2 核心指标详细对比表——模型选型(qwen\llama)

由于时间和资源原因llama模型暂时没有继续过充分验证，无法保证效果。



llama3.3-70b报告.pdf
125.33KB



***llama模型8b的走到模型tool调用会自己停掉，70b的模型报告只有文字。从现象上看llama应该是需要单独兼容。*

4.3 私有部署建议结论

1. 首推方案：对于绝大多数私有化客户，强烈推荐使用“推荐门槛模型 (32B)”方案（国内建议qwen3、GML、MiniMax、DeepSeek，国外建议Llama 3.x、Gemma3、Mixtral）。在4-bit（int4）量化下，只需要24GB显存即可运行（参考下方表格），硬件投入比旗舰级节省约 60%，但能保留旗舰级 85%-90% 的业务能力。

精度模式	模型权重占用	KV Cache (上下文预留)	总显存需求 (推荐)
FP16 / BF16 (原版)	~62 GB	+ 2~10 GB	> 70 GB
Int8 (8-bit 量化)	~34 GB	+ 2~8 GB	> 40 GB
Int4 (4-bit 量化)	~19.5 GB	+ 2~4 GB	24 GB
Int4 + 长上下文	~19.5 GB	+ 10 GB+	32 GB - 48 GB

2. 多场景深度分析方案：如果客户业务涉及复杂场景分析、深度推理或多样化任务处理，建议升级至“推荐旗舰模型”。该模型具备更强的语义理解与推理能力，可适配更专业的业务需求。

3. **红线预警：**除非客户明确表示仅用于“跑通流程”或“界面展示”，否则**坚决不建议**在正式生产环境部署 **8B** 模型，否则后期会面临大量的“分析不准”、“报告乱码”的客诉风险。

4.4 不同Agent推荐模型大小表

Agent	Qwen 8B	Qwen 32B	Qwen 235B	描述
分析报告	不推荐	推荐	高配推荐	
场景驱动/调度	不推荐 (输出的指令不够准确)	强力推荐	一般 (能力溢出，但推理延迟高，导致交互卡顿。)	
知识检索	推荐 (更推荐、成本更低)	推荐	不推荐	
数据分析	不推荐	推荐 (能力很强，非复杂场景足够用，性价比高)	强力推荐 (推理能力强，能够结合业务深度分析)	后续版本内容
故障诊断及方案推荐	不推荐	推荐	强力推荐	后续版本内容
工单执行	不推荐	强力推荐	推荐	后续版本内容


5. 部署方案与成本参考 (供售前报价参考)

5.1 FAI 大模型部署方案全景对比表

方案代号	方案 A：SaaS 公有云(云端直连)	方案 B：私有化-体验版(最小规模 7/8B)	方案 C：私有化-标准版(推荐门槛 32B)	方案 D：私有化-旗舰版(高性能 70B+)
适用场景	互联网接入允许、追求最高性价比、无涉密要求的通用客户。	仅限售前演示、个人笔记本体验、非关键业务流程跑通。不推荐生产环境。	大多数私有化客户的首选。平衡了成本与效果，适合企业内部生产环境。	集团总部、军工/涉密单位、对分析深度有极高要求的科研场景。

模型选型	GPT-5.1 / DeepSeek-V3.2 (跟随更新最新模型)	Qwen-8B / Llama-8B	Qwen-32B / Gemma3-32B	Qwen3-235B / Llama-3.3-70B / DeepSeek
硬件建议	N/A (云端处理)	不低于8GB显存	应用节点： 不低于8*CPU 不低于16*GB内存 LLM节点： 不低于24GB显存	应用节点： 不低于8*CPU 不低于16*GB内存 LLM节点： 不低于160GB显存
典型硬件配置(仅供参考)	无需服务器	单张消费级显卡 (RTX 4070/3070Ti/4090)	工作站/服务器(1x RTX 4090 或 1x A10/A30)	高性能服务器集群(2x A800-80G 或 4x A40/L40S)
硬件参考成本(预估)	0元	1万~2万(主要为高配PC成本)	4万~8万(工作站或入门服务器)	30万~60万+(企业级AI服务器)
软件订阅成本	按年订阅或按量付费	包含在私有化License中	包含在私有化License中	包含在私有化License中
实施周期	即时 (账号开通即用)	1-3天 (软件安装)	1-2周 (硬件采购+环境部署)	1-2周 (硬件采购+环境部署)
运维复杂度	极低 (厂商负责)	中 (需客户IT协助)	中高 (需专业运维巡检)	高 (需专业机房环境支持)
核心优势	模型永远最新、最强；初期投入几乎为零。	极其便宜，可离线运行，满足基本的数据不外流。	性价比高；能力足够胜任大部分分析任务，硬件成本可控。	极致的分析能力；数据绝对安全；逻辑推理能力更强。
核心劣势	数据需出域；长期大量调用订阅费可能累积。	能力太弱；容易产生幻觉；无法处理长报告。	需定期维护硬件；模型更新需厂商介入。	极其昂贵；电力功耗大；硬件贬值快。

5.2 技术架构图



6. 常见问题应答 (FAQ)

Q1: 为什么你们不推荐私有化部署7/8B的小模型？我的电脑都能跑。

A: 工业仿真分析需要极强的逻辑推理能力来分析产能瓶颈。7/8B模型就像“小学生”，能读通顺句子，但看不懂复杂的生产报表，会导致分析出的结论误导生产决策。为了对您的产线负责，我们建议起步使用“研究生”级别的模型（32B+）。

Q2: 为什么你们推荐的私有化硬件这么贵？我自己有几张3070Ti显卡能用吗？

A: 3070Ti显卡显存较小且不支持NVLink高速互联，运行大模型推理时速度会非常慢（生成一个字可能要几秒），且容易爆显存导致服务崩溃。为了保证各位“生成报告”时不卡顿、不报错，我们需要企业级硬件支撑。

Q3: 用DeepSeek（公有云）会不会泄露我们的工程数据？

A: DeepSeek作为国内合规厂商，其API服务遵循严格的数据隐私协议，通常不使用API数据进行模型训练。如果您的企业有极高的保密要求（如涉密资质），我们建议使用私有化部署方案，实现物理隔离。

Q4: DeepSeek这么便宜，为什么还要用微软？

A: DeepSeek性价比极高，非常适合国内环境。但在某些极度复杂的长逻辑推理或多语言混合场景下，微软GPT5目前的稳定性仍是全球最佳。我们的FAI架构支持灵活切换，您可以根据预算选择。

Q5: 私有化部署后，模型怎么升级？

A: 这就是私有化的弊端。通常需要我们的工程师上门或远程重新部署新的镜像，这可能涉及到额外的服务费用。且如果新模型变大了，您现有的硬件可能跑不动，需要再次采购硬件。